

# Multimodal Retrieval-Augmented Generation for Korean Documents

이도현, 박서연, 김민준 · Modu AI Lab · 2026

## Abstract

본 논문은 한국어 비정형 문서를 위한 멀티모달 RAG 프레임워크를 제안한다. 텍스트, 표, 이미지를 단일 검색 공간에 통합 임베딩하여 정확도 87.3%를 달성했다.

## 1. Introduction

최근 LLM은 인상적인 성능을 보이나 한국어 비정형 문서 처리에서는 표·이미지를 무시하는 한계가 있다. 본 연구는 GPT-4o Vision과 임베딩을 결합해 이를 해결한다.

## 2. Method




Figure 1: Proposed RAG pipeline

Figure 1. 제안하는 멀티모달 RAG 파이프라인

전체 파이프라인은 4단계로 구성된다: (1) 문서 파싱, (2) 인코딩, (3) 검색, (4) 생성. 각 요소(텍스트/표/이미지)는 독립적으로 캡처링된 후 단일 벡터 공간에 임베딩된다.

## 3. Equations

검색 점수는 dense와 sparse를 가중합으로 결합한다:

$$\text{score}(q, d) = \alpha \cdot \cos(E(q), E(d)) + (1 - \alpha) \cdot \text{BM25}(q, d)$$

어텐션은 표준 정의를 따른다:  $\text{Attention}(Q, K, V) = \text{softmax}(QK^T / \sqrt{d_k}) V$

## 4. Results




Figure 2. Training/Validation loss (Ours vs Baseline)

| Method            | Recall@5 | MRR   | Latency(ms) |
|-------------------|----------|-------|-------------|
| BM25              | 0.612    | 0.421 | 12          |
| Dense (text-only) | 0.748    | 0.582 | 45          |
| Multimodal (ours) | 0.873    | 0.712 | 78          |

Table 1. 검색 성능 비교

## 5. Conclusion

제안 방법은 텍스트 전용 베이스라인 대비 Recall@5에서 12.5%p 향상을 보였다. 후속 연구로는 비디오 모달리티 확장과 한국어 외 다국어 적용을 계획한다.